

方法：同循环一致性约束与扩展自监督预训练

问题定义与数据形态

本文面向“片段级在线 SOH 估计”任务：给定电池某个循环内一段长度为额定容量 20% 的部分充电片段，估计该循环的健康状态 SOH。任务之所以必要，是因为真实车载与云端系统中电池往往只经历部分充电而非完整循环；片段级估计可直接在线部署，无需等待完整充放电循环结束。

以 Severson 等[1]公开的 LFP 快速充电数据集为例说明数据形态。每个循环的充电曲线（电流 $I(t)$ 、电压 $V(t)$ 、温度 $T(t)$ ）经安时积分得到容量坐标 $Q(t)$ （数据集自带），随后对容量轴重参数化：以额定容量 $C_{\text{nom}} = 1.1 \text{ Ah}$ 的 1%（即 0.011 Ah）为基本单元，每个 1% 区间内插值出 5 个等距点，从而把 20% 容量窗口离散为 $T = 101$ 个时间步。片段起点在 0%–50% 额定容量之间以 1% 步长滑动，因此同一循环最多可切出 51 个片段。记第 c 个循环的第 i 个片段输入为

$$x_{c,i} \in \mathbb{R}^{101 \times 3}, \quad (1)$$

其三个通道依次为电流 I 、电压 V 与容量坐标 Q 。对应的监督标签是循环级标量 SOH：

$$s_c = \frac{C_c}{C_{\text{nom}}} \in \mathbb{R}, \quad (2)$$

其中 C_c 为该循环由安时积分得到的可充电容量。这里有一个对后文至关重要的结构性质：**同一循环的所有片段共享同一个标签 s_c** ，尽管它们的起点 SOC、电压轨迹与极化状态各不相同。

值得注意的是，我们目前的模型并没有温度的输入，这是因为：**Severson** 的数据集中电池的运行状况会在恒温箱中进行，无法从数据源解释温度的含义，之后我们会加入含变温度的数据集。

基础模型：共享编码器与两阶段迁移学习

模型遵循文献[2]的迁移学习框架。编码器由两层线性嵌入与一层 LSTM 组成：

$$\text{Emb} : \mathbb{R}^3 \rightarrow \mathbb{R}^{32}, \quad \text{LSTM} : \mathbb{R}^{32} \rightarrow \mathbb{R}^{64}. \quad (3)$$

输入 $x \in \mathbb{R}^{101 \times 3}$ 逐时间步嵌入后送入 LSTM，得到逐时刻隐藏状态 $h_1, \dots, h_{101} \in \mathbb{R}^{64}$ 。三个输出头共享该编码器：


- 电压预测头 $g_v : h_t \mapsto \hat{V}_{t+1}$ ，用于自监督预训练；
- SOH 回归头 $g_s : h_{101} \mapsto \hat{s}$ ，用于微调；
- 重建头 $g_r : h_t \mapsto \hat{V}_t$ ，用于本文新增的掩码重建任务。

预训练目标为“下一步电压预测”：

$$\mathcal{L}_{\text{vol}} = \frac{1}{B(T-1)} \sum_{b=1}^B \sum_{t=1}^{T-1} (g_v(h_{b,t}) - V_{b,t+1})^2, \quad (4)$$



其监督密度为每个时间步一个目标（密集监督）；相比之下，SOH 监督每个循环仅有一个标量（稀疏监督）。文献[2]指出，正是这种“密集—稀疏”的落差使迁移学习有效：编码器先在电压演化这一密集任务上学习电化学响应规律，再将学到的表征迁移至稀疏的 SOH 回归。微调阶段仅替换输出头，数据损失为

$$\mathcal{L}_{\text{data}} = \frac{1}{N} \sum_{n=1}^N (g_s(h_{n,101}) - s_n)^2. \quad (5)$$




结果分析


训练损失曲线 (基线配置, 10 + 10 epoch)



测试集 SOH 预测 vs 真值 (n=30,000)
MAE = 2.26% RMSE = 2.77% $R^2 = 0.6932$



典型测试电池的 SOH 老化轨迹 (片段级预测 vs 真实值)



创新点一：同循环一致性约束

具体内容。 由式 (1)–(2) 可知，同一循环的多个片段共享一个 SOH 标签，却对应互不相同的输入。本文据此引入同循环一致性约束：训练时采用分组采样，每个批次包含 G 个循环、每个循环随机抽取 K 个片段（实验中 $K = 4$ ），并惩罚同一循环内 K 个预测之间的离散程度：

$$\mathcal{L}_{\text{consist}} = \frac{1}{G} \sum_{c=1}^G \frac{1}{K} \sum_{i=1}^K (\hat{s}_{c,i} - \bar{s}_c)^2, \quad \bar{s}_c = \frac{1}{K} \sum_{i=1}^K \hat{s}_{c,i}. \quad (6)$$

微调阶段的总损失为

$$\mathcal{L} = \mathcal{L}_{\text{data}} + \lambda_{\text{consist}} \mathcal{L}_{\text{consist}}, \quad (7)$$

默认 $\lambda_{\text{consist}} = 1.0$ 。

为什么这样设计。 有三层依据。

其一，物理依据：老化是一个慢过程，同一循环内部容量几乎不变，SOH 在循环尺度上近似常数。因此“同循环输出一致”不是人为施加的偏置，而是电池退化的物理先验。

其二，统计依据：单一片段只是该循环的“局部视角”，起点 SOC 与极化状态不同会导致单片段观测含有较大噪声；若只对每个片段独立回归，模型容易拟合片段特有的伪影。一致性约束相当于在多个视角之间施加正则化，迫使模型学习与起点无关的老化表征，从而降低估计方差。

其三，部署依据：现有工作[3]表明，在同一循环内聚合多片段特征可显著提升容量估计精度；但聚合操作要求测试时也能拿到同循环的多个片段，破坏了“任意单片段在线推理”的能力。本文将其思想转化为训练期的一致性正则化——约束只作用于训练目标，推理时仍可输入任意单个片段直接输出 SOH，兼顾精度与在线可用性。此外，式 (6) 只负责拉近组内输出，SOH 的绝对水平仍由式 (5) 锚定，因此不会出现把全部预测压向同一常数的退化（塌缩）解。

创新点二：扩展自监督——掩码电压重建

具体内容。 预训练阶段在式 (4) 之外新增掩码电压重建任务：以比例 $\rho = 0.3$ 随机遮蔽电压通道，并用该片段的电压均值填充被遮蔽位置（而非填 0，以免制造易被模型识别的异常跳变），随后要求重建头在被遮蔽位置还原原始电压：

$$\mathcal{L}_{\text{recon}} = \frac{1}{|M|} \sum_{(b,t) \in M} (g_r(h_{b,t}) - V_{b,t})^2, \quad (8)$$

其中 M 为遮蔽位置集合。预训练总损失为

$$\mathcal{L}_{\text{pre}} = \mathcal{L}_{\text{vol}} + \lambda_{\text{recon}} \mathcal{L}_{\text{recon}}, \quad (9)$$

默认 $\lambda_{\text{recon}} = 1.0$ 。

为什么这样设计。 式 (4) 的“下一步电压预测”在电压平滑的区域（尤其是 LFP 的电压平台期）可以被一种退化的短程复制策略近似满足：因为相邻步电压变化很小，模型只需“照抄”上一步即可获得较低损失，未必真正理解曲线结构。遮蔽重建迫使模型仅凭电流、容量坐标与未被遮蔽的邻近电压推断缺失值，从而学习电压曲线在容量轴上的平滑性、平台位置与拐点等全局结构。这一设计与文献[2]的“密集监督”论点一脉相承：重建把监督从逐点预测扩展为结构性理解。多任务自监督（预测 + 重建 + 去噪）的做法亦有直接文献支持，如 xPatch[4] 在电池时序上的重建/去噪/预测联合预训练，以及掩码自编码器[5]在通用表示学习中的成功。

训练目标与消融设计

综上，训练分两阶段：预训练最小化式 (9)，微调最小化式 (7)。核心超参数为 $\lambda_{\text{consist}} = 1.0$ 、 $\lambda_{\text{recon}} = 1.0$ 、遮蔽比例 $\rho = 0.3$ 、组内片段数 $K = 4$ ；为保证消融公平，分组采样每个 epoch 的更新次数与普通采样按样本数对齐。消融矩阵包含五组配置：基线（论文复现）、只改采样（令 $\lambda_{\text{consist}} = 0$ ，隔离采样方式的影响）、仅加一致性约束、仅加掩码重建、完整方案，从而逐一量化两个创新点的独立贡献与协同效应。

架构改进方向与文献支撑

改进动机：当前观测范围的信息缺口

当前模型以固定 20% 额定容量的部分充电片段为输入，片段起点在 0%–50% 之间以 1% 步长滑动，因此单片段观测的容量覆盖上限为 70%。然而，对原始数据的实测表明：本数据集每个循环实际充电至约 97% 额定容量（两个恒流段后进入 3.6 V 恒压段，电流衰减至约 C/50），即完整循环为 0%→满充→0%。这意味着 70%–97% 的高 SOC 区间——恒压补电段——被现有数据组织方式完全排除。而该区间恰好是极化与内阻增长最敏感的观测区域，对老化表征具有独特价值。据此，本文提出三个层次的架构改进，并由文献逐层支撑。

改进一：扩展可观测 SOC 范围（数据层）

将 SOH 回归任务的片段起点上限由 50% 放宽至 77%（片段末端最高达 97%），使模型可观测高 SOC 与恒压段；电压预训练任务因需要观测窗之后的 7% 容量预测窗，起点上限保持 70%。约束可写作

$$s + 0.2 \leq q_{\max}^{\text{SOH}}, \quad s + 0.2 + 0.07 \leq q_{\max}^{\text{pre}},$$

其中 s 为片段起点（额定容量比例）， $q_{\max}^{\text{SOH}} = 0.97$ 、 $q_{\max}^{\text{pre}} = 0.90$ 。该改进不改动模型结构，仅调整数据构建参数，且已有的 `is_valid_soh` / `is_valid_pretrain` 双标记体系天然支持两类任务的分开约束。

不同 SOC 区间的老化信息量并不相同，已有工作专门研究区间选择与融合——如基于不同 SOC 区间的容量估计集成与选择方案（*J. Energy Storage*, 2022）、面向部分充电条件的自适应电压区间特征构造（*Energy*, 2024）、以及用互信息引导电压段选择的不完整充电曲线 SOH 估计（*J. Power Sources*, 2026）。这些工作共同表明：观测区间的位置直接影响估计精度，扩展至高 SOC 区间具有明确的信息论动机。

改进二：变长前缀观测与在线刷新（架构层）

固定窗口的隐含假设是“只有某一段充电曲线可用”；真实在线场景中，充电是从 0 开始逐步推进的。为此，本文提出变长前缀观测：将“充电开始至当前进度 x ”的整段前缀作为输入，

$$x_{\text{prefix}}(x) = \{(I, V, Q) \mid 0 \leq Q \leq x\}, \quad x \in [x_{\min}, 0.97],$$

其中 Q 为容量坐标，前缀长度随 x 增长（按 0.2% 额定容量步长，5% 进度约 25 点，97% 进度约 485 点）。共享 LSTM 编码器天然支持变长序列，SOH 估计随充电进度动态刷新；同一循环在不同进度 x 下产生的前缀样本共享同一 SOH 标签，因此同循环一致性约束自然推广为“同一循环内不同进度前缀的输出一致”：

$$\mathcal{L}_{\text{consist}} = \frac{1}{C} \sum_{c=1}^C \frac{1}{K} \sum_{k=1}^K (\hat{s}_{c,k} - \bar{s}_c)^2, \quad \bar{s}_c = \frac{1}{K} \sum_{k=1}^K \hat{s}_{c,k},$$

其中 K 个前缀取自同一循环的不同进度。固定 20% 窗口可视为该框架的特例（从 0 开始的定长前缀）。

1. 部分充电曲线可估 SOH：面向部分充电曲线的数据驱动 SOH 估计（IEEE, 2024，查尔姆斯理工）与基于部分充电曲线的电压重建模型（*J. Energy Storage*, 2021）均证明无需完整循环；
2. 片段灵活性与变长输入：灵活深度学习方法表明“随部分充电曲线长度增加，提取特征依然有效，测试 RMSE < 1.5%”（*Batteries*, 2024）；基于随机生成的部分充电片段与增量能量曲线（IES）的 SOH 估计（*Energy*, 2024）；基于碎片化充电容量的可用容量估计（*Communications Engineering*, 2025）更以“less is more”为原则，用任意碎片充电数据完成容量估计；

3. 在线与增量刷新：基于增量学习的残差容量闭环估计（IEEE, 2024，可在充电操作中重训练）、增量 LS-SVR 在线 SOH 估计（2023）、以及从 CCCV 充电恒流段在线提取健康因子的 GPR+EKF 框架（IEEE, 2025）均支持“随数据到达持续更新”。

改进三：多窗口/分阶段融合（可选扩展）

在共享编码器之上引入双分支结构：低 SOC 段与高 SOC 段各过一个编码器，特征拼接后进入 SOH 头，

$$\hat{s} = g_s\left([h_{T_1}^{(1)}; h_{T_2}^{(2)}]\right),$$

其中 $[\cdot; \cdot]$ 表示拼接， $h_{T_1}^{(1)}$ 、 $h_{T_2}^{(2)}$ 分别为两个片段经共享 LSTM 后的末时刻状态。该结构可视为结构化多视角融合，与随机取 K 个同循环片段的一致性约束互补。

不同 SOC 区间的集成与选择方案（*J. Energy Storage*, 2022）与同循环多片段特征聚合提升容量估计精度（arXiv:2504.00393）为该方向提供了直接依据。

研究边界

上述文献分别支撑“部分充电可估”“区间信息差异”“在线更新”三个事实，但“变长前缀观测 + 充电进度动态刷新 + 前缀间一致性”的整体设计在现有文献中未见完整实现。本文将其作为自主贡献，采用“三个文献支柱 → 综合设计 → 消融验证”的论证结构：

现有工作分别证明了部分充电可估 SOH、不同 SOC 区间信息量存在差异、以及估计可随充电过程在线更新。然而，鲜有方法将三者统一：在单次充电内随进度动态刷新 SOH，并保证不同进度的估计彼此一致。为此，本文提出变长前缀观测机制……

风险与公平性

- 变长前缀最长约 485 点，计算量高于固定 20% 窗口，批内长度不齐需按长度分桶或 padding；
- 前缀样本“看得更多”，与固定窗口基线对比时必须控制观测长度（如单 40% 窗口对照），避免“输入变长所以更准”的混淆；
- 恒压段电流形态随协议与老化变化，属于跨协议分布差异来源，需在消融中单独报告。

实验设置总览

1. 公共设置（所有配置一致）

项目	设置
数据集	Severson LFP (A123 APR18650M1A, 1.1 Ah), 恒温 30°C
数据划分	按电池划分; train 4,064,721 片段 / test 870,416 片段
片段定义	20% 额定容量观测窗; 起点 0–50% (1% 步长); 每 1% 容量插值 5 步 → 101 点
模型输入	(101, 3) = [I, V, Q], 原始单位 (未做 z-score)
SOH 标签	soh_nominal = Q_charge / 1.1 Ah
模型	共享 LSTM 编码器 (嵌入 3→128→32, LSTM hidden=64) + 电压头 / 重建头 / SOH 头 (64→128→1); 55,075 参数
优化器	Adam, lr=1e-3, weight_decay=0, 梯度裁剪=1.0
训练预算	预训练 10 epoch (下一步电压预测, MSE) + 微调 10 epoch (SOH 回归, MSE)
有效 batch	4096
随机种子	42
数据读取	memmap 磁盘缓存 (build_cache.py 一次性物化)
评估	测试集 MAE / RMSE (%)

2. 消融配置矩阵

#	配置	采样方式	一致性损失	掩码重建	目的
1	baseline 基线	普通 shuffle	无	无	论文复现参照
2	grouped_control 只改采样	循环分组 (1024 循环 × 4 片段)	$\lambda=0$ (关闭)	无	隔离“分组采样”的影响
3	consistency 同循环一致性	循环分组 (1024 循环 × 4 片段)	$\lambda=1.0$	无	创新 1: 同循环多片段输出一致
4	recon 掩码重建	普通 shuffle	无	$\lambda=1.0$, 遮 30% 电压	创新 2: 扩展自监督 (仅预训练)
5	full 完整方案	循环分组 (1024 循环 × 4 片段)	$\lambda=1.0$	$\lambda=1.0$, 遮 30% 电压	两个创新叠加

3. 当前结果 (持续更新)

配置	Test MAE	Test RMSE	状态
baseline 基线	2.2651%	2.7706%	完成

配置	Test MAE	Test RMSE	状态
grouped_control 只改采样	—	—	训练中
consistency 同循环一致性	—	—	待跑
recon 掩码重建	—	—	待跑
full 完整方案	—	—	待跑

参考文献

[1] K. A. Severson et al., “Data-driven prediction of battery cycle life before capacity degradation,” *Nature Energy*, vol. 4, pp. 383–391, 2019.

[2] 片段级部分充电 SOH 估计的迁移学习框架, *Scientific Reports*, 2026, DOI 10.1038/s41598-026-48906-4.

[3] 基于同循环片段聚合的钠离子电池容量估计, arXiv:2504.00393.

[4] xPatch: 基于重建/去噪/预测多任务自监督的电池时序预训练, *Energy*, 2025.

[5] K. He et al., “Masked autoencoders are scalable vision learners,” CVPR, 2022.