

片段数据预测

关于数据构成部分不多赘述，详见[20260811汇报 > 数据集](#)

传统上，电池 SOH 通常在相对受控的实验室条件下，通过完整充电或放电曲线进行评估。但在电动汽车和大规模储能系统等实际场景中，充电常常从任意荷电状态开始，并在充满之前结束。这种实际限制促使研究者关注基于部分充电数据的 SOH 估计。

注意这里我们说的是“充电”，因为学者们普遍认为：放电时期的数据相较于充电往往更难获得（而且就算获得了，受限于不同使用场景，驾驶者的不同习惯，数据质量不会太高）。所以本次 SOH 在线估计我们使用如下的 SOH 定义：

$$\text{SOH} = \frac{\text{当前可充电容量}}{\text{额定容量}}$$

传统定义上来说，SOH 应该为：

$$\text{SOH} = \frac{\text{当前放电容量}}{\text{额定容量}}$$

毕竟一块电池充满电之后，以能放出多少电量为 SOH 的标准更加符合定义，本部分采用了“当前可充电容量” = “当前放电容量” 的假设

方法论

迁移学习

不是训练模型只从单个部分充电片段直接推断 SOH，而是先让循环网络在电压预测任务上预训练，再把学习到的表征迁移到 SOH 估计。理由是电压预测在每个时间步都提供稠密监督，而 SOH 标签在循环级别上很稀疏。如果循环层已经学会刻画主导短期电压演化的隐藏动态因素，那么微调 SOH 估计就可能比从头训练更省数据、更鲁棒。从这个意义上说，本文框架不只是通用的迁移学习，而是一种机制驱动的策略：源任务被选择为能够促使网络内化具有物理意义的时间结构。

使用迁移学习的原因

实测充电电压不仅受当前电流和长期退化状态影响，还受电池潜在内部动态状态影响。即使两段充电遵循相似的外部电流协议，由于内部极化状态强烈依赖最近运行历史并随时间弛豫，它们的电压轨迹也可能不同。极化和弛豫行为的重要性在电化学电池建模中早已被认识，近期研究也表明弛豫信号可以帮助揭示锂析出等退化现象。此外，可变快充策略通过改变电荷转移、输运限制和退化演化之间的相互作用，进一步增加了电压响应的复杂性。因此，部分充电数据中不仅包含退化信息，还包含 BMS 中无法直接观测的、依赖历史的瞬态电化学信息。

问题描述

让一个电池单元产生一系列逐周期的测量数据。在第 k 个周期，充电过程记录两条时间序列：电压 $V(t)$ 与电流 $I(t)$ ，容量吞吐 $Q(t)$ 由安时积分近似获得。放电容量与内阻需要实验室级设备测量，因此不纳入模型输入。

模型不接收完整充电曲线，而是接收一个**部分充电片段**：从 0%–50% 额定容量中的某个起点开始，截取 20% 额定容量的充电窗口，并按容量坐标等距重采样为 101 个时间步。每个时间步的输入由三通道组成——电流 $I(t)$ 、电压 $V(t)$ 与容量步（固定步长 $d = 0.0022$ Ah），即输入张量 $X \in \mathbb{R}^{101 \times 3}$ 。

模型接收一个片段，产生一个输出：

$$\hat{s}(k) = \text{当前循环 } k \text{ 的 SOH (标量)}$$

训练采用迁移学习：先在电压预测任务上预训练——接收同一片段，预测其后 7% 额定容量窗口内的电压序列；收敛后保留循环层参数，仅替换输出头，并微调用于 SOH 回归。SOH 定义为当前**可充电容量**与额定容量的比值：

$$s(k) = \frac{Q_{\text{charge}}(k)}{Q_{\text{nominal}}}, \quad Q_{\text{nominal}} = 1.1 \text{ Ah}$$

与之前的结果相比来说：

实验使用 Severson 等人公开的 LFP/石墨数据集，共 124 只电池（排除 1 只异常短寿命电池后为 123 只，99 只训练 / 24 只测试），额定容量 1.1 Ah，在多组快充协议下循环至寿命终点（容量保持率 80%）。

数据集划分

按照该数据集先前预处理惯例，排除一只寿命异常短的极端异常电池。剩余电池被划分为 99 只训练电池和 24 只测试电池。测试集中包含共享协议和独特协议下的电池，因此评估既反映在已知充电模式内的插值，也反映对较少出现协议设置的泛化能力。所有内部比较都使用相同的训练/测试划分和相同的预处理流程。

模型结构

编码器。 每个时间步的三维输入先经过共享的嵌入网络：先由 $W_1 \in \mathbb{R}^{128 \times 3}$ 映射到 128 维，再由 $W_2 \in \mathbb{R}^{32 \times 128}$ 压缩为 32 维嵌入。嵌入序列随后送入 LSTM，其隐藏状态与细胞状态维度均为 64。LSTM 的细胞状态可视为对近期输入历史的滤波记忆：遗忘门与输入门控制先前信息衰减的速率与新信息整合的方式，这一性质与极化状态在变化输入下逐渐积累、

在激励移除后逐渐弛豫的定性行为一致。隐藏状态则将该内部表示与当前输入结合，用于预测下一时刻电压。

迁移学习。 直接 SOH 监督是稀疏的——一个循环内 SOH 近似恒定；而电压预测监督在每个时间步都稠密。因此，模型先在电压预测任务上预训练：电压头（64 → 128 → 1）在每一步预测下一时刻电压，损失为预测电压与观测电压向后平移一位之间的均方误差。电压模型收敛后，保留嵌入层与 LSTM 的循环参数，仅将电压头替换为 SOH 头（64 → 128 → 1），并微调用于 SOH 回归，输出当前循环的标量 SOH。（两阶段各 50 epoch、Adam、学习率 10^{-3} 、批大小 4096、梯度裁剪 1.0）

训练问题

项目	值
硬件	RTX 3060 Laptop（6 GB 显存），conda env battery-soh
数据	123 只电池（99 train / 24 test），约 493 万片段
输入	(101, 3) 部分充电片段，通道为 I、V、容量坐标 Q
标签	SOH = 可充电容量 / 1.1 Ah（论文口径）
模型	LSTM 共享编码器 + 双头，约 4.7 万参数
阶段 1	电压预测预训练：下一步电压，MSE
阶段 2	SOH 回归微调：替换输出头，MSE
优化器	Adam，lr 1e-3，梯度裁剪 1.0
批大小	4096（20000 会 OM，8192 贴边）
计划	预训练 50 epoch + 微调 50 epoch
预加载	约 6 分钟，曲线全部驻留内存（约 2 GB）
当前进度	预训练已完成 2/50 epoch（loss 0.120 → 0.00036）

预加载：原实现每读一个循环就重开一次 MAT 文件（约 25 分钟），而且 preload 的缓存上限只有 8192，预加载的曲线会被大量淘汰，等于白加载。改为复用文件句柄 + 取消缓存上限后，预加载降到约 6 分钟。

数据口径：片段合法性只检查了 end_ah <= q_max，漏了 start_ah >= q_min。有约 10 个循环的充电记录开头缺失（Qc 从 0.007~0.066 Ah 才开始），导致 31 个片段在插值时崩溃。已在 segments.py 修复合法性判断并重建索引。